

Diplomado de Analítica y Ciencia de Datos

Dr. Juan Baldemar Garza Villegas

juan.garza@udem.edu



- Practitioner....

.... *Y académico....*

... Interesado en la Mejora Continua, Ciencia de Datos,
Tecnología, Estrategia 4.0 y.....

... MEJORES EMPRESAS...

1

MLOps y Drift ML

ANTECEDENTE

ML OPS

...

22% de las empresas que usan ML han implementado con éxito un modelo de ML en producción


87% de los proyectos de ciencia de datos nunca llegan a producción.

State of Enterprise ML de Algorithmia (Ahora DataRobot) de 2020

QUÉ ES DEV OPS



Las **operaciones** son las diferentes acciones, desde el punto de vista del Desarrollo de software, que se realizan durante el **ciclo de vida del software** desde su fase inicial hasta su fase final.




QUÉ ES DEV OPS

...


¿Qué es DevOps?

“

DevOps es la unión of **personas**, **procesos** y **productos** para habilitar la entrega continua de valor a tus usuarios finales.”




CICLO ML OPS



CICLO ML OPS



El proceso de ciencia de datos en equipo



CICLO ML OPS



Un proyecto típico de Machine Learning



PROBLEMAS


ML OPS



- No hay un seguimiento del trabajo realizado
 - ¿Qué datos se han utilizado?
 - ¿Qué código se ha probado en cada ocasión?
 - ¿Qué combinación de código y datos produjeron X modelo?
 - ¿Cuáles fueron las métricas del modelo X?
- No siempre se generan entregables (“artefactos”)
- No se puede reproducir (repetir) un modelo
- No es posible pasar el modelo y todas sus variables (código, entorno, datos, etc) con facilidad

DS / ML OPS

ML OPS




DS / ML OPS

ML OPS

...

MLOps



DS / ML OPS

ML OPS




- MLOps permite a los científicos de datos y a los desarrolladores de aplicaciones ayudar a llevar los modelos de machine learning a producción.
- MLOps le permite realizar un seguimiento / gestionar versiones / auditar / certificar / reutilizar cada activo en su ciclo de vida de ML y proporciona servicios de orquestación para agilizar la gestión de este ciclo de vida.

MONITOREO ML OPS

...


ML MODEL DECAY MONITORING



MONITOREO ML OPS



Integrated Pipeline for Data Scientists and Software Engineers



BENEFICIOS

ML OPS



- Reproducibilidad
 - El código impulsa las implementaciones
 - Los pipelines son reproducibles y verificables
 - Todos los artefactos se pueden etiquetar y auditar
- Validación
 - Mejores prácticas de Ingeniería de Software para el control de calidad
 - Comparaciones sin conexión de la calidad del modelo
 - Minimice el bias y habilite la explicabilidad
- Automatización
 - Capacidades de implementación controlada
 - Comparación en vivo del rendimiento previsto frente al esperado
 - Resultados retroalimentados para observar la deriva y mejorar el modelo

RIESGOS **ML OPS**



- **Deriva (Drift) en la data del modelo.**
- **Falta de control de versiones**
- **Falta de automatización**
- **Falta de monitoreo**
- **Falta de escalabilidad**
- **Falta de seguridad**

DIFERENCIAS EN DEV OPS &

ML OPS




- Control de versiones de datos / modelo! = Control de versiones de código: cómo versionar conjuntos de datos a medida que cambian el esquema y los datos de origen
- Los requisitos de seguimiento de auditoría digital cambian cuando se trata de código + datos (potencialmente del cliente)
- La reutilización de modelos es diferente a la reutilización de software, ya que los modelos deben ajustarse en función de los datos de entrada / escenario.
- Para reutilizar un modelo, es posible que deba ajustar / transferir el aprendizaje en él (lo que significa que necesita un pipeline de entrenamiento)
- Los modelos tienden a deteriorarse con el tiempo y necesita la capacidad de volver a capacitarlos a pedido para garantizar que sigan siendo útiles en un contexto de producción.

HERRAMIENTA ML OPS



MLFlow

- MLFlow es un rastreador de experimentos y un servidor de modelos genérico. Puede ser autohospedado.
- Los experimentos se rastrean mediante el uso de enlaces de biblioteca para registrar parámetros (modelo), resultados de evaluación y cargar artefactos (como modelos, hashes de datos de entrenamiento o incluso código). Los artefactos se pueden registrar en el almacenamiento local, remoto o en la nube (S3, GFS, etc.).




Los resultados se pueden analizar a través de una interfaz de usuario web y la exportación CSV está disponible. Los modelos se empaquetan como un contenedor alrededor del formato subyacente (Sklearn, XGBoost, Torch, etc.). Se pueden enviar a Spark para la inferencia por lotes o se pueden servir a través de REST.

Hay API de CLI, Python, R, Java y REST para una mayor integración con las canalizaciones de CI / CD. Los modelos se pueden enviar a servicios en la nube (SageMaker, AzureML, ...).

NIVELES ML OPS




El nivel de operacionalización o automatización depende del grado de automatización de las operaciones del proceso MLOps.



NIVELES ML OPS



Nivel de automatización 0: Despliegue manual de modelos




Proceso Manual de generación de modelos: Desconexión entre el AA y las operaciones debido a que los **científicos de datos** compilan el modelo, que es entregado a los ingenieros como un **artefacto** y a los **ingenieros** despliegan este modelo como un servicio de predicción (inferencia).

NIVELES ML OPS



Nivel de automatización 1: Automatización del proceso de aprendizaje



Proceso Automatizado

Simetría experimental-operacional

Versionado automático de modelos

Modularización de componentes

No existe Integración Continua (IC)

Entrega Continua de modelos

Implementación de la canalización de AA


Monitorización y Registro del Modelo

Proceso automático de la generación de modelos: Conexión directa entre el AA y las operaciones debido a que el proceso de generación del modelo está automatizado y es reproducible. Los **científicos de datos** puedes desplegar de manera automática nuevos modelos sin intervención directa de los **ingenieros**.

NIVELES ML OPS




Nivel de automatización 2: Automatización del proceso de Integración Continua



Proceso completamente automatizado de la generación y despliegue de modelos: Existe una completa automatización del proceso de desarrollo, entrenamiento y despliegue de modelos. La introducción de IC/EC permite que los **científicos de datos** exploren rápidamente nuevas ideas con respecto a la ingeniería de atributos, la arquitectura y los hiperparámetros.

NIVELES ML OPS AZURE



VERSIONADO

ML OPS

...

Código V1 → [Modelo de Machine Learning] ← Datos V1

Código V2 → [Modelo de Machine Learning] ← Datos V2

Código V3 → [Modelo de Machine Learning] ← Datos V3

CONCLUSIONES

ML OPS



MLOps se enfoca en los siguientes aspectos:

- **Deriva (Drif)**: para rastrear cambios en la data del modelo y sus resultados.
- **Control de versiones**: para rastrear cambios en el modelo y sus resultados.
- **Automatización**: para automatizar el proceso de entrenamiento, prueba y despliegue del modelo.
- **Monitoreo**: para monitorear el rendimiento del modelo en producción.
- **Escalabilidad**: para manejar grandes volúmenes de datos y modelos complejos.
- **Seguridad**: para garantizar la seguridad de los datos y el modelo.
- **Cambio**: Gestión del cambio sostenido

JD-UV
INSPIRANDO
TU MEJOR
VERSIÓN

Drift ML Deriva ML

[Evidently](#) is an “open-source framework to evaluate, test and monitor ML models in production.”

DERIVA DRIFT



En el aprendizaje automático, la desviación del modelo significa que el modelo de aprendizaje automático se vuelve cada vez menos preciso debido a los cambios en las propiedades estadísticas de las características de entrada, la variable de destino o las relaciones entre variables.

Los datos en los que se entrena el modelo de aprendizaje automático se denominan datos de entrenamiento o datos de origen.

Los datos sobre los que el modelo intenta predecir se denominan datos de servicio o datos de destino.

Las distribuciones de datos de entrenamiento/origen pueden ser diferentes de las distribuciones de datos de destino/servicio.

DERIVA DRIFT



¿Por qué ocurre el Drift - Deriva?

- Estacionalidad:** cambios regulares y predecibles en los datos que se repiten cada año calendario
- Preferencias del consumidor:** lo que preferimos cambia con el tiempo. Lo que nos gusta hoy puede no ser lo que nos gusta mañana.

Algunos ejemplos de las formas en que los datos a los que se aplica y se entrena un modelo pueden ser significativamente diferentes son:

El mundo externo ha cambiado: estos pueden ser eventos externos como la pandemia y los cambios en las tasas de interés, o podrían ser eventos más internos, como una falla en los pipe lines de los modelos que conducen a problemas de calidad de los datos.

El modelo se aplica a un nuevo contexto: por ejemplo, un modelo de lenguaje entrenado en datos de wikipedia se aplica a los artículos de noticias.

Los datos de entrenamiento se extrajeron de un conjunto diferente en primer lugar: esto puede deberse a sesgos de selección de muestras. A veces estos sesgos son inevitables.

DERIVA DRIFT



¿Cuáles son los diferentes tipos de deriva?

Cuando se habla de deriva, pueden surgir varios términos estrechamente relacionados: cambio de covariable, deriva de concepto, deriva de datos, deriva de modelo, decaimiento de modelo, cambio de conjunto de datos, cambio de distribución. Estos términos se refieren a diferentes suposiciones sobre lo que está cambiando.

- **Desplazamiento covariable:** la distribución de las características de entrada cambia.
- **Deriva conceptual:** la relación entre la variable objetivo y las características de entrada cambia.
- **Decaimiento del modelo:** caída en el rendimiento del modelo debido a la deriva.
- **Deriva de datos:** cualquier cambio distributivo. Esto a veces se usa en su lugar para referirse específicamente al **cambio covariable**.
- Los otros términos (**cambio de distribución, cambio de conjunto de datos**) generalmente pueden referirse a cualquiera de los conceptos anteriores o a una combinación de ellos.

DERIVA DRIFT



El enfoque estándar para identificar la deriva es medir el rendimiento del modelo (precisión o de otro tipo) o examinar o medir las diferencias en las distribuciones de capacitación e implementación de:

- 1.resultados previstos,
- 2.aterrizar la verdad,
- 3.funciones de entrada individuales, o
- 4.características de entrada conjunta.

Todos estos enfoques proporcionan señales valiosas de deriva, y deben usarse siempre que sea posible. Sin embargo, en la práctica tienen serios desafíos que hacen que la medición de la deriva sea un problema difícil.

DERIVA

DRIFT



Maldición de la dimensionalidad — A medida que aumenta el número de características de las dimensiones en los datos, se vuelve cada vez más difícil distinguir las muestras extraídas de dos distribuciones. Esto hace que la medición de la deriva conjunta entre múltiples características sea especialmente difícil y puede afectar la medición de la deriva en predicciones o modelos de múltiples clases con múltiples salidas. La maldición también es la razón por la cual una verificación directa de la deriva del concepto (una propiedad de la distribución conjunta de todas las características de entrada y salida) puede ser poco práctica. Esto, sin embargo, puede ser discutible debido al próximo desafío.

Falta de verdad sobre el terreno — Una prueba del rendimiento del modelo en el despliegue puede ser suficiente para determinar si la deriva fue lo suficientemente significativa como para justificar la intervención. Desafortunadamente, la verdad sobre el terreno en el despliegue puede no estar disponible de inmediato. Por ejemplo, en la decisión de crédito, si un préstamo conduce a un incumplimiento puede no estar disponible hasta que el período del préstamo haya pasado varios meses o años después. En este contexto, la deriva del concepto no puede determinarse de forma independiente aparte de otras formas de deriva de datos.

DERIVA DRIFT



Deriva intrascendente: a menudo es difícil identificar el impacto de los problemas de deriva en el modelo. A menudo, un gran cambio en una característica puede ser intrascendente porque cambia de una manera que no afecta el comportamiento del modelo. Junto con el hecho de que siempre se espera que haya algún grado de deriva, puede ser realmente difícil clasificar si vale la pena abordar un problema de deriva.

Estos desafíos significan que cualquiera que sea el medio de detección de la deriva empleado en la práctica, puede ser un indicador impreciso de la deriva real y de las consecuencias reales. Es importante, entonces, tener en cuenta los costos de los enfoques para abordar la deriva.

DERIVA DRIFT



- **Básicamente, es una forma de responder a las preguntas rápidamente:**

¿El objetivo del modelo se comporta de manera similar al período anterior?

¿Las predicciones de mi modelo siguen siendo las mismas?

Si algo cambia, puede explorar más a fondo:

¿Qué ha cambiado exactamente?

¿Qué características es probable que contribuyan al cambio?

¿Hay nuevos segmentos de datos a los que prestar atención?

DERIVA DRIFT



- **Una vez más, es necesario preparar dos *Pandas DataFrames*.** El primero es su conjunto *de datos de referencia*. Por lo general, estos son los datos que utiliza para entrenar su modelo. El segundo son los datos de *producción* más recientes.

Estos marcos de datos pueden incluir solo los valores predichos, solo los valores reales o ambos.

En función de lo que predice, puede elegir entre dos tipos de informe:

NumTargetDrift funciona para cualquier instrucción de problema en la que se prediga un objetivo numérico. (Kolmogorov-Smirnov)

- **CatTargetDrift** se aplica a los casos en los que su objetivo es categórico. Por ejemplo, una clasificación binaria o una clasificación multiclase. (Chi cuadrada)

Seleccione el tipo de informe y se servirán todos los gráficos y perspectivas.

ML OPS PYTHON

DRIFT




DOCS

LEARN

COMMUNITY

GITHUB

GET EARLY ACCESS



Data Drift


Run statistical tests to compare the input feature distributions, and visually explore the drift.

GET STARTED

Target Drift

Understand how model predictions and target behavior change over time.

GET STARTED



Prediction drift is **detected** (95% significance).

It will generate a HTML report locally.

Drift is detected for 0.00% of features (0 out of 7). Dataset Drift is NOT detected.

Search						
Feature	Type	Reference Distribution	Current Distribution	Data Drift	Stat Test	Drift Score
> charges	num	[Histogram]	[Histogram]	Not Detected	K-S p_value	0.770437
> children	num	[Histogram]	[Histogram]	Not Detected	K-S p_value	0.935112
> sex	cat	[Histogram]	[Histogram]	Not Detected	Z-test p_value	0.89933
> smoker	cat	[Histogram]	[Histogram]	Not Detected	Z-test p_value	0.64363
> region	cat	[Histogram]	[Histogram]	Not Detected	chi-square p_value	0.630943
> age	num	[Histogram]	[Histogram]	Not Detected	K-S p_value	0.329358
> bmi	num	[Histogram]	[Histogram]	Not Detected	K-S p_value	0.172556

7 rows | < > 1/7 of 7 >


DERIVA DRIFT



Deriva numérica del objetivo

Para Numerical Target Drift, su informe mostrará primero la comparación de las distribuciones objetivo:

Target Drift: not detected, $p_value=0.914721$



DERIVA DRIFT



Si no se detecta ninguna deriva, lo más probable es que esté listo para comenzar. No está pasando nada importante.


En este ejemplo, la herramienta ha detectado una deriva (basada en la [prueba de Kolmogorov-Smirnov de dos muestras](#) a un nivel de confianza de 0,95).

Cuando esto sucede, querrás ver los cambios principales rápidamente. La herramienta hace precisamente eso. Traza los valores objetivo de los conjuntos de datos de *referencia* y *producción* para la comparación visual. Utilizamos index o DateTime, si está disponible.


DERIVA DRIFT

A continuación, el informe muestra el cambio en las correlaciones entre las características individuales y el objetivo. Utilizamos el coeficiente de [correlación de Pearson](#). Aunque no todas las relaciones son lineales, puede ser útil. Un cambio significativo en un coeficiente de correlación puede apuntar a la fuente del cambio.

Target Correlations



Target Values



DERIVA DRIFT



Para profundizar más, damos una visión general del comportamiento de cada característica. Esto nos ayuda a entender si pueden explicar el cambio de objetivo.



DERIVA DRIFT



- Aquí están nuestras sugerencias sobre cuándo usarlo:

1. Antes del reciclaje del modelo.

Antes de introducir datos nuevos en el modelo, es posible que desee verificar si tiene sentido.

Cuando nada cambia, lo más probable es que una actualización no mejore el rendimiento.

Cuando las cosas cambian demasiado, el reentrenamiento ciego puede no ser suficiente.

Si observa cambios específicos en los datos o la función de destino, es posible que desee:
agregar o eliminar ciertas características;

realizar ingeniería de características adicionales;

introducir nuevas reglas de negocio o hacer modelos de conjunto para dar cuenta de nuevos segmentos.

El informe le ayudará a decidir si ciertas características o segmentos necesitan atención.

DERIVA DRIFT



2. Cuando se está depurando el modelo se descompone.

Si ya observa una caída en el rendimiento, este informe puede ayudarle con la depuración. Te muestra rápidamente lo que ha cambiado para que sepas cómo explicarlo y abordarlo.

3. Cuando estás volando a ciegas, y no hay verdad terrestre disponible.

No tener retroalimentación inmediata no es razón para ignorar su modelo. Puede ejecutar este informe cada vez que genere predicciones por lotes o programar algunas comprobaciones.

Al observar qué cambia exactamente, puede anticipar los datos y la deriva del concepto. En algunos casos, puede decidir pausar el modelo. Por ejemplo, si sospecha de un cambio significativo o se enfrenta a un problema de calidad de datos.

¡ GRACIAS !