

Diplomado de Analítica y Ciencia de Datos

Dr. Juan Baldemar Garza Villegas

juan.garza@udem.edu



- Practitioner....

.... *Y académico*....

... Interesado en la Mejora Continua, Ciencia de Datos,
Tecnología, Estrategia 4.0 y.....

... MEJORES EMPRESAS...

1

Web Scrapping

Introducción al Web Scraping

Conceptos, herramientas y consideraciones



¿Qué es el Web Scraping?

El Web Scraping es una técnica para extraer información de sitios web de manera automatizada. Se utiliza para recopilar datos de páginas web sin necesidad de realizar tareas manuales repetitivas.

Usos Comunes del Web Scraping

- Investigación de mercado: precios y productos.
- Análisis de datos: tendencias y comportamientos.
- Ciencia de datos: datasets no estructurados.
- Automatización: actualizaciones dinámicas.
- Agregadores: comparadores de precios.

Herramientas y Tecnologías

- Librerías en Python: BeautifulSoup, Scrapy, Selenium.
- JavaScript: Puppeteer para navegadores.
- APIs: Alternativas estructuradas.
- Herramientas SaaS: Octoparse para scraping sin programación.


¿Qué es Octoparse?

- Octoparse es una herramienta de web scraping visual y sin código, diseñada para usuarios que no tienen experiencia en programación.

Permite:

- Extraer datos de sitios web con interfaces simples.
- Manejar contenido dinámico y múltiples niveles de navegación.
- Exportar datos en formatos como Excel, CSV y bases de datos.

¿Qué es Octoparse?



The screenshot displays the Octoparse web application. At the top, the navigation bar includes the Octoparse logo, links for Solutions, Templates, Download, Pricing, and Resources, a Login button, and a prominent blue button labeled 'Start a free trial'. The main content area shows a list of tasks with columns for Task Name, Cloud Status, and Action. A modal window titled 'Cloud Schedules' is open, allowing users to configure task execution. This modal includes sections for 'Settings' (with a 'Save' button), 'Recurrence' (with radio buttons for Once, Weekly, Monthly, and Interval), 'Weekly' (with checkboxes for days of the week, where Sunday is selected), and 'Run at' (with a grid of time slots, where 01:00 is selected). At the bottom of the modal are 'Schedule OFF' and 'Schedule ON' buttons. The background task list shows three tasks: 'Task 1' (My Group 4 hours ago), 'Task 2' (My Group a day ago), and 'Task 3' (My Group 7 days ago). A sidebar on the right contains several icons for different functionalities. At the bottom of the interface, it indicates 'Total 3 tasks: showing 1-10' and provides pagination controls.

Automation that goes above and beyond

Ventajas de Octoparse

- Interfaz intuitiva y sin necesidad de programación.
- Soporte para scraping de contenido dinámico.
- Funcionalidades avanzadas como scraping en la nube.
- Ideal para usuarios no técnicos y proyectos rápidos.

Ética y Legalidad del Web Scraping

- Revisar términos de servicio del sitio web.
- Usar los datos extraídos de forma responsable.
- Respetar las directrices del archivo robots.txt.
- Considerar el uso de APIs oficiales cuando sea posible.

Conclusión

El web scraping es una herramienta poderosa para extraer datos de internet. Con herramientas como Octoparse y librerías de programación, es posible automatizar tareas y generar valor a partir de la información obtenida.

¡ GRACIAS !